NLP подходи за категоризация на алгоритмични задачи на български език

Теодор Светославов Костадинов, ф.н. 5MI3400816 Подходи за обработка на естествен език, зимен семестър 2025/2026

1. Въведение

Всяка година от 2018 г. насам в курса по Структури от данни и алгоритми се добавят около 30 нови задачи. С нарастването на броя задачи, подготовката на студентите и намирането на подобни задачи за упражнение става все по-трудно. Целта на настоящия проект е подобряване на достъпа до учебните материали чрез автоматично извличане и класифициране на алгоритмични задачи на български език с помощта на NLP подходи. Извличането и класифицирането на задачите са ключови стъпки за решаването на този проблем.

2. Данни

Източник на данни

Използван е публичен исторически списък на всички състезания, давани по СДА от 2018 г. насам, достъпен като Google документ. Данните са извлечени от платформата HackerRank, където са публикувани условията на задачите.

Формат и обем

Корпусът се състои от **329 текстови файла**, всеки съдържащ условието на една задача в суров текстов формат. Към всеки файл е присвоена категория, определяща класа на задачата. Първоначалният документ е конвертиран в CSV формат, след което условията на задачите са извлечени от HackerRank в JSON формат. Използваните атрибути включват текста на условието и категорията.

Анотиране

Анотирането на данните е извършено чрез слабо анотиране с OpenAI агент. Класовете задачи са дефинирани според категориите лекции по конспекта на курса. Резултатните класове включват: binary_search_tree, linked_list, graph_traversal, shortest_path, sorting, dynamic_programming, stack_queue, priority_queue, hash_table, tree, minimum_spanning_tree и searching.

3. Метод

a. Основни обработки от компютърната лингвистика

- **Нормализация на текста** - премахване на HTML тагове, пунктуация, привеждане към малки букви
- **Токенизация и лематизация** - чрез библиотеката **Classla**, специализирана за южнославянски езици
- **POS tagging** - филтриране по части на речта: NOUN, PROPN, ADJ, VERB
- **Премахване на стоп-думи** - използване на stopwordsiso за български език
- **Извличане на признаци** - униграми, биграми и глаголи

b. Допълнителни алгоритми

- **PMI-базирано индуциране на правила** - за всеки клас се избират до 30 cue думи с най-висок PMI score. Използвано в Експерименти I и II.

- **Intent/Slot Extraction** - ръчно дефинирани cue думи за извличане на topic, 12 класа, и paradigm, 6 типа. Използвано в Експеримент III.
- **TF-IDF + Cosine Similarity** - векторно представяне на лематизиран текст, униграми и биграми, и търсене на подобни задачи чрез косинусова прилика. Използвано в Експеримент IV.
- **Стратифицирано разделяне** train/test 80/20 за оценка на моделите.

4. Експерименти

Експеримент I: Rule-based PMI класификатор

PMI-базиран rule-based класификатор върху български текст. NLP pipeline-ът включва Classla и филтриране на стоп-думи. Признаците са леми, униграми, биграми, глаголи и key_phrases от анотациите. За всеки клас се индуцират Top-30 правила с положителен PMI score.

Метрика	**Стойност**
Accuracy	0.333 (22/66)
Перфектни класове (F1=1.0)	binary_search_tree, linked_list
Неточни класове (F1=0.0)	dynamic_programming, priority_queue, stack_queue, tree

Клас	**Precision**	**Recall**	**F1**	**Support**
binary_search_tree	1.00	1.00	1.00	6
linked_list	1.00	1.00	1.00	2
shortest_path	1.00	0.40	0.57	5
graph_traversal	1.00	0.30	0.46	10
sorting	0.44	0.36	0.40	11
minimum_spanning_tree	0.17	1.00	0.29	2
dynamic_programming	0.00	0.00	0.00	13

Класове с характерна лексика като BST и linked_list се разпознават перфектно, но класове дефинирани чрез техника на решение като DP и stack_queue нямат лексикални сигнали и получават F1 = 0.

Експеримент II: PMI Cue Extraction със слети класове

Същият PMI подход, но с обединени класове чрез LABEL_MAP от 12 на 7 класа: graph_traversal, shortest_path и MST са обединени в **graph**; binary_search_tree и tree в **tree_structure**; linked_list, stack_queue и priority_queue в **linear_structure**. Оценка чрез Top-K accuracy върху 31 тестови примера.

Метрика	**Стойност**
Top-1 Accuracy	0.226 (7/31)
Top-3 Accuracy	0.645 (20/31)
Top-5 Accuracy	0.903 (28/31)
Cue Overlap	0.968 (30/31)

Правилният клас попада в Top-5 в 90.3% от случаите, но searching доминира като Top-1 предсказание поради твърде общи правила. Сливането на класовете намалява броя тестови примери от 66 на 31, но не подобрява Top-1 accuracy.

Експеримент III: Intent/Slot Extraction

Ръчно дефинирани slot правила с лематизирани cue думи за български, например за tree: дърво, възел, корен, лист, поддърво; за graph_traversal: граф, обход, връх, ребро, цикъл. Извличане на topic, 12 класа, и paradigm, 6 типа. Оценка на topic slot срещу OpenAI анотации върху 329 примера.

Метрика	Стойност
Accuracy	0.307
Macro Precision	0.236
Macro Recall	0.196
Macro F1	0.186

Accuracy от 30.7% е сходна с PMI класификатора, но macro F1 от 0.186 е по-нисък. Ръчните cue думи са ограничени и не покриват разнообразието на текстовете. Предимство на подхода е възможността за извличане на допълнителни структурирани атрибути.

Експеримент IV: TF-IDF Similarity Search

Лематизиран текст, представен като TF-IDF вектори с униграми и биграми. Cosine similarity между всяка задача и останалите с leave-one-out оценка, като за всяка задача се търсят Top-5 най-подобни.

Метрика	Стойност
P@1	0.511
P@3	0.441
P@5	0.423
MRR	0.614
MAP@5	0.587
Общо заявки	329

Клас	P@1	Брой
binary_search_tree	0.842	38
linked_list	0.840	25
graph_traversal	0.673	52
shortest_path	0.600	20
sorting	0.500	44
dynamic_programming	0.368	68
stack_queue	0.348	23
hash_table	0.219	32

P@1 = 51.1% е значително подобрение спрямо rule-based подходите от около 30%. MRR = 0.614 показва, че правилният клас обикновено е в първите 2 резултата. BST и linked_list отново водят с над 84%, докато DP с 36.8% и hash_table с 21.9% остават трудни за разпознаване.

5. Резултати и дискусия

Обобщение на резултатите

Експеримент	Метрика	Стойност
I. PMI класификатор	Accuracy	0.333
II. PMI със слети класове	Top-1	0.226
II. PMI със слети класове	Top-5	0.903
III. Intent/Slot Extraction	Accuracy	0.307
IV. TF-IDF Similarity	P@1	0.511
IV. TF-IDF Similarity	MRR	0.614

Анализ на грешките

Лексикален сигнал. Класове с характерна терминология като binary_search_tree и linked_list се разпознават надеждно от всички подходи, F1 = 1.0 при PMI и P@1 над 84% при TF-IDF. За задачи, в чийто условия присъстват ключови думи като "дърво", "възел", "свързан списък", NLP подходите работят ефективно.

Абстрактни концепции. Класове, дефинирани чрез техника на решение като dynamic_programming и stack_queue, нямат лексикални сигнали в условията си и остават най-трудни за класификация, F1 = 0 при PMI и P@1 = 36.8% за DP при TF-IDF. Условието на задачата описва проблема, а не метода на решение.

Ръчни срещу автоматични правила. Ръчно дефинираните cue думи от Експеримент III не подобряват резултатите спрямо автоматичния PMI подход, 30.7% срещу 33.3%, тъй като не покриват разнообразието на текстовете.

TF-IDF превъзходство. Векторното TF-IDF представяне постига най-добри резултати с P@1 = 51.1%, като улавя контекста по-добре от отделни cue думи, но остава ограничено от bag-of-words представянето.

Top-K потенциал. При PMI със слети класове правилният клас попада в Top-5 в 90.3% от случаите, което показва че подходът е полезен за стесняване на кандидатите дори при нисък Top-1 accuracy.

6. Заключение и бъдеща работа

Проектът демонстрира приложимостта на NLP подходи за категоризация на алгоритмични задачи на български език. TF-IDF similarity search постига най-добри резултати с P@1 = 51.1% и MRR = 0.614, докато rule-based подходите са ефективни за класове с ясна терминология. Основното ограничение на всички подходи е невъзможността за класифициране на задачи, чийто клас се определя от метода на решение, а не от лексиката на условието.

Насоки за бъдеща работа:

- **Transformer embeddings** - използване на многоезичен модел като multilingual BERT за по-богато семантично представяне, което да улови абстрактни алгоритмични концепции отвъд лексикалното ниво
- **Подобряване на анотациите** - ръчна проверка и корекция на OpenAI етикетите за по-надеждна оценка на моделите
- **Уеб интерфейс** - интеграция на similarity search в студентски портал за търсене на подобни задачи, което директно да подпомогне подготовката на студентите по СДА